

Active Learning para la detección de cardiomegalia en radiografías de tórax

Xabat Arin and Aimar Hernandez

Abstract

Las enfermedades detectables mediante imágenes médicas, como las radiografías, constituyen un desafío clínico relevante, cuyo diagnóstico suele depender de la interpretación de radiólogos expertos. En los últimos años, los modelos de aprendizaje profundo han alcanzado un alto rendimiento en la detección automática de diversas patologías, como la neumonía, la atelectasia o la cardiomegalia, siendo CheXNet uno de los ejemplos más destacados. A pesar de que estos modelos de aprendizaje profundo hayan demostrado un gran potencial en el ámbito de la imagen médica, su desarrollo está limitado por el elevado costo y la gran cantidad de datos etiquetados que se necesita para su entrenamiento. Para abordar este problema, se han comparado distintas estrategias de Active Learning utilizando conjuntos de datos clínicos reales de radiografías de tórax, y proponiendo un marco que minimiza la cantidad de datos requeridos manteniendo el rendimiento. En este proyecto se propone un modelo basado en CheXNet donde identifica los pacientes con cardiomegalia.

1 Introducción

Las enfermedades detectables mediante imágenes médicas, como las radiografías de tórax, representan un desafío clínico relevante, ya que su diagnóstico depende de la correcta interpretación de los especialistas. Entre ellas, la cardiomegalia constituye una de las patologías respiratorias más frecuentes y potencialmente graves a nivel mundial. Su detección temprana resulta esencial para reducir complicaciones y mejorar la supervivencia de los pacientes. En los últimos años, los avances en el aprendizaje profundo han permitido el desarrollo de

modelos de redes neuronales convolucionales capaces de analizar radiografías automáticamente, como CheXNet[1], uno de los más reconocidos en el ámbito del diagnóstico por imagen. No obstante, el entrenamiento de estos modelos requiere grandes volúmenes de datos etiquetados, lo que implica una limitación significativa en contextos clínicos, ya que se carece de estos datos etiquetados por lo costosos que son.

Con el objetivo de abordar esta limitación, en este proyecto se propone un sistema de diagnóstico asistido basado en CheXNet, empleado sobre

un conjunto de 5606 imágenes médicas de radiografías de tórax, combinando aprendizaje profundo con técnicas de Active Learning y Transfer Learning. En primer lugar, para simplificar el problema a la clasificación de una sola clase, se ha hecho inferencia sobre el conjunto de test con un modelo preentrenado semejante al ChexNet [2]. Una vez hecha la inferencia, se ha elegido la enfermedad cardiomegalia y se ha aplicado fine tuning sobre el modelo para adaptarlo a una clasificación binaria. Posteriormente, se desarrollaron varios modelos de Active Learning, manteniendo un 10% fijo para testeo y utilizando el 90% restante para la aplicación de las estrategias de selección activa. Dentro de este 90%, se definieron conjuntos etiquetados de 20%, 30%, 50% y 70%, considerando el resto como datos no etiquetados, siguiendo un enfoque de pool-based sampling.

Con el fin de seleccionar las muestras más informativas, se implementaron diversas estrategias de adquisición, incluyendo Random Sampling, Entropy Sampling, Margin Sampling, Least-Confident Sampling, Monte Carlo Dropout [3] ($p = 0.3$ y $p = 0.5$) y el método MedAL [4]. Estas técnicas permiten estimar la incertidumbre o representatividad de cada imagen y priorizar las más relevantes para su anotación. Las radiografías en las que el modelo presenta mayor incertidumbre son derivadas a revisión médica, cuyas nuevas etiquetas se incorporan iterativamente al conjunto de entrenamiento, mejorando de manera progresiva la capacidad del sistema con un número reducido de ejemplos anotados.

Este enfoque, fundamentado en la combinación del modelo CheXNet con estrategias de Active Learning, busca

reducir el costo de anotación, aumentar la eficiencia del proceso de aprendizaje y ofrecer una herramienta de diagnóstico asistido más robusta, fiable y adaptable al entorno clínico real.

2 Estado del arte

En este apartado se aborda el estado del arte relacionado con el proyecto presentado. En primer lugar, se presentan los avances más relevantes en la detección automática de patologías en radiografías de tórax. En segundo lugar, se revisan las técnicas de Active Learning, tanto en su desarrollo general como en sus aplicaciones específicas dentro del ámbito médico, destacando los métodos que han demostrado mayor eficacia en la optimización del proceso de anotación y mejora del rendimiento de los modelos.

2.1 ChexNet: Detección de patologías

CheXNet es un gran avance en la detección automática de neumonía a partir de radiografías de tórax [1], que plantea el problema como una tarea de clasificación binaria (neumonía vs. no neumonía) y propone un modelo basado en una DenseNet-121[5] entrenada sobre el conjunto de datos ChestX-ray14.

El modelo se entrena mediante transfer learning, inicializando los pesos con una red preentrenada en ImageNet y ajustándolos posteriormente mediante optimización end-to-end, lo que permite aprovechar representaciones visuales previamente aprendidas en un dominio amplio para aplicarlas a uno clínico, donde la obtención de etiquetas resulta costosa. Como mecanismo de interpretabilidad, CheXNet incorpora Class Activation Maps (CAMs), que permiten

visualizar las regiones de la imagen que más contribuyen a la predicción del modelo, siguiendo la formulación clásica de las CAM propuesta en el ámbito de la visión por computador [6].

Desde el punto de vista arquitectónico, la elección de DenseNet se fundamenta en su esquema de conectividad densa, lo que resultan especialmente ventajosas en redes profundas utilizadas como backbone para tareas de diagnóstico por imagen. En la figura 1 se puede observar la arquitectura de la red.

Layers	Output Size	DenseNet-121	DenseNet-169	DenseNet-201	DenseNet-264
Convolution	112 × 112		7 × 7 conv, stride 2		
Pooling	56 × 56		3 × 3 max pool, stride 2		
Dense Block (1)	56 × 56	1 × 1 conv 3 × 3 conv × 6	1 × 1 conv 3 × 3 conv × 6	1 × 1 conv 3 × 3 conv × 6	1 × 1 conv 3 × 3 conv × 6
Transition Layer (1)	56 × 56		1 × 1 conv		
Dense Block (2)	28 × 28	1 × 1 conv 3 × 3 conv × 12	1 × 1 conv 3 × 3 conv × 12	1 × 1 conv 3 × 3 conv × 12	1 × 1 conv 3 × 3 conv × 12
Transition Layer (2)	28 × 28		2 × 2 average pool, stride 2		
Dense Block (3)	14 × 14	1 × 1 conv 3 × 3 conv × 24	1 × 1 conv 3 × 3 conv × 32	1 × 1 conv 3 × 3 conv × 48	1 × 1 conv 3 × 3 conv × 64
Transition Layer (3)	14 × 14		2 × 2 average pool, stride 2		
Dense Block (4)	7 × 7	1 × 1 conv 3 × 3 conv × 16	1 × 1 conv 3 × 3 conv × 32	1 × 1 conv 3 × 3 conv × 32	1 × 1 conv 3 × 3 conv × 48
Classification Layer	1 × 1		7 × 7 global average pool 1000D fully-connected, softmax		

Fig. 1 La arquitectura DenseNet-121 consta de 121 capas entrenables, organizadas en cuatro Dense Blocks (de 6, 12, 24 y 16 capas) separados por tres Transition Layers. Cada dense layer sigue un esquema bottleneck, favoreciendo la reutilización de características y un flujo de gradiente eficiente. Al contabilizar las convoluciones de cada bloque, junto con la inicial, las de transición y la final, se alcanza el total de 121 capas.

Además del modelo orientado a la detección de neumonía, los autores desarrollaron una versión extendida capaz de identificar catorce patologías torácicas diferentes mediante un enfoque de clasificación multilabel.

2.2 Estrategias de Active Learning

El Active Learning busca reducir el esfuerzo de etiquetado seleccionando de forma iterativa las muestras más útiles

para mejorar el modelo. A través de distintas estrategias de consulta (query strategies), se determina qué ejemplos son más informativos, equilibrando la incertidumbre del modelo y la representatividad de los datos. Existen tres escenarios principales para la formulación de consultas (queries): *Pool-based sampling*, *Stream-based selective sampling* y *Query synthesis*. Para este proyecto se ha utilizado el enfoque de *Pool-based Sampling*. En este escenario se dispone de un amplio conjunto de datos no etiquetados (pool). El modelo evalúa iterativamente este conjunto, selecciona las muestras más informativas para su etiquetado por el oráculo y las incorpora al conjunto de entrenamiento.




Fig. 2 Esquema del ciclo de *Pool-based Sampling*.

A la hora de determinar qué instancias son las más idóneas para ser consultadas, las estrategias de selección se dividen fundamentalmente en tres categorías principales: *Uncertainty-based sampling*, *Diversity-based methods* y *Expected model change*. En este proyecto. Este marco de trabajo, se ha centrado en el enfoque de *Uncertainty-based sampling*. Dentro de esta categoría, se han analizado los siguientes tres métodos para cuantificar la incertidumbre del modelo:

Margin Sampling:

El muestreo por margen se centra en los ejemplos que presentan la menor diferencia entre las probabilidades de las dos clases más probables. Este margen pequeño sugiere que el modelo está indeciso entre sus dos mejores predicciones. Se define maximizando:

$$1 - (p_1 - p_2), \quad (1)$$

donde p_1 y p_2 son las probabilidades ordenadas de forma descendente.

Entropy:

Esta métrica selecciona las instancias con mayor entropía de predicción, es decir, aquellas cuya distribución de probabilidad es más incierta. La función objetivo se define como:

$$-\sum_k p_k \log(p_k), \quad (2)$$

seleccionando las instancias cuya distribución predicha es más cercana a una distribución uniforme [7].

Monte Carlo Dropout (MC Dropout):

El MC Dropout es una técnica probabilística que permite estimar la incertidumbre epistémica. Consiste en mantener activadas las capas de *Dropout* durante la fase de inferencia, realizando múltiples pasadas hacia adelante (*forward passes*) estocásticas sobre una misma instancia. Esto produce una distribución empírica de predicciones, cuya varianza o dispersión se utiliza como medida directa de incertidumbre del modelo [3].

2.2.1 Active Learning en medicina

El uso de Active Learning en el ámbito médico ha cobrado especial relevancia en los últimos años, ya que permite reducir significativamente el volumen de datos etiquetados necesario para entrenar modelos de aprendizaje profundo, un factor crítico en entornos donde la anotación manual requiere la intervención de especialistas. Este enfoque busca optimizar el proceso de aprendizaje seleccionando de forma iterativa las muestras más informativas o inciertas del conjunto no etiquetado, mejorando así la eficacia del modelo con un menor esfuerzo de anotación.

En el estudio *Active Learning in Brain Tumor Segmentation with Uncertainty Sampling and Annotation Redundancy Restriction* [8], se analiza el impacto de diferentes estrategias de selección de muestras en tareas de segmentación de tumores cerebrales. Los autores destacan que la incorporación de *Monte Carlo Dropout* [3], entrenando el modelo con dropout en la última capa convolucional, ofrece una estimación de incertidumbre más estable y mejora los resultados. De acuerdo con estos hallazgos, dicha técnica ha sido adoptada también en este proyecto para reforzar la fiabilidad de la estimación de incertidumbre.

Por otro lado, el estudio *MedAL: Accurate and Robust Deep Active Learning for Medical Image Analysis* [4] propone un enfoque que combina el muestreo de datos en función de la entropía de predicción, que mide la incertidumbre del modelo, con una segunda fase en la que se evalúa la distancia en el espacio de características extraído por una red convolucional profunda. De este modo,

primero se identifican las imágenes sobre las que el modelo muestra mayor incertidumbre y, entre ellas, se seleccionan aquellas que son más diferentes de las ya presentes en el conjunto de entrenamiento. Esta combinación integra los criterios de incertidumbre y representatividad, permitiendo elegir muestras más informativas y diversas para mejorar progresivamente el rendimiento del modelo. Dado los buenos resultados obtenidos, este método se ha implementado también en el proyecto, definiendo la distancia del coseno como métrica para calcular la similitud en el espacio de características.




Fig. 3 Esquema del proceso propuesto de la implementación de MedAL

En la figura 3 se muestra el proceso de este método. La idea general del artículo es la siguiente. En primer lugar, se entrena un modelo y posteriormente se utiliza para consultar ejemplos del conjunto no etiquetado, que luego se añaden al conjunto de entrenamiento. En este trabajo se propone una nueva función de consulta, más adecuada para modelos de aprendizaje profundo. El modelo se emplea para extraer características tanto

de los ejemplos del *oracle* como del conjunto de entrenamiento, y se filtran las muestras del *oracle* con baja entropía predictiva. Finalmente, se selecciona la muestra del *oracle* que, en promedio, se encuentra a mayor distancia en el espacio de características respecto a todas las imágenes del conjunto de entrenamiento, definida por:

$$s(x) = \frac{1}{N} \sum_{i=1}^N d(f(x_i), f(x)), \quad (3)$$

donde $f(x)$ representa el vector de características extraído por la red para la imagen x , $d(\cdot, \cdot)$ es la distancia euclídea en el espacio de representaciones y N es el número de muestras en el conjunto de entrenamiento etiquetado. Las muestras seleccionadas son aquellas que maximizan $s(x)$:

$$x^* = \arg \max_{x \in D_{\text{oracle}}} s(x). \quad (4)$$

En los marcos de Active Learning, tras incorporar nuevas anotaciones, existen dos estrategias principales para actualizar el modelo: reentrenar desde cero con todos los datos disponibles o hacer *fine-tuning* en el modelo existente utilizando solo las nuevas muestras, o bien una combinación de estas.

En el artículo *A survey on active learning and human-in-the-loop deep learning for medical image analysis* [7] se presentan los trabajos realizados sobre este tema. En general, el reentrenamiento completo es más costoso computacionalmente, pero ofrece una evaluación más consistente del rendimiento del marco de Active Learning, mientras que el *fine-tuning* es más eficiente y común en

áreas como transfer learning o few-shot learning. Aun así, la elección óptima entre ambas estrategias sigue siendo una cuestión abierta y depende del contexto y los recursos disponibles.

3 Metodología

En esta sección se detalla el marco experimental diseñado para evaluar el rendimiento de distintas estrategias de *Active Learning* aplicadas a la clasificación de radiografías de tórax. El proceso se ha dividido en cuatro etapas principales: la preparación y preprocesamiento de los datos, la adaptación de la arquitectura base obtenida de un repositorio externo [2], la configuración del entrenamiento, y finalmente, la implementación del ciclo iterativo de aprendizaje activo.

3.1 Conjunto de Datos y Preprocesamiento

Para el desarrollo de este proyecto se ha utilizado un subconjunto de 5.606 imágenes extraídas de la base de datos ChestX-ray14. El problema se ha formulado como una tarea de clasificación binaria enfocada exclusivamente en la detección de *Cardiomegalia*. Al analizar la distribución de las etiquetas originales en el archivo de metadatos, se constató un fuerte desbalance de clases, con tan solo 141 imágenes positivas (representando un 2,52% del total) frente a 5.465 imágenes negativas.

Con el fin de garantizar una evaluación robusta, se ha realizado una partición estratificada del conjunto de datos. En primer lugar, se reservó un 10% de las imágenes como conjunto de testeo estático, el cual no participa en ninguna fase de entrenamiento ni de selección

de imágenes. El 90% restante conformó el *pool* principal, a partir del cual se generaron distintos escenarios iniciales asignando el 20%, 30% y 60% de los datos como subconjuntos etiquetados (*labeled pool*), quedando el resto como datos no etiquetados (*unlabeled pool*). De cada conjunto etiquetado inicial, se extrajo adicionalmente un 10% para labores de validación.

Para aumentar la generalización del modelo y mitigar el sobreajuste provocado por el desbalance, se han aplicado técnicas de (*Data Augmentation*). Específicamente, se ha integrado una política estocástica denominada *XRaysPolicy*, diseñada para aplicar transformaciones como rotaciones, ecualizaciones, variaciones de contraste y posterización. Adicionalmente, las imágenes se han redimensionado a 256x256 píxeles, aplicando recortes aleatorios (*RandomResizedCrop*) a 224x224, volteo horizontal aleatorio y normalización basada en los estadísticos de ImageNet.

3.2 Arquitectura del Modelo y Adaptaciones

La implementación técnica de este proyecto toma como base el código de un repositorio de GitHub orientado a la replicación de CheXNet [2]. Sin embargo, para adecuarlo a los objetivos de este estudio, se han introducido adaptaciones estructurales y funcionales significativas sobre el código original.

En primer lugar, se ha empleado la arquitectura DenseNet-121, y se ha inicializado con los pesos del modelo presentado en el repositorio. El repositorio original estaba diseñado para clasificar 14 patologías torácicas distintas. Para

este trabajo, se ha reemplazado la capa lineal final del clasificador original por una nueva red secuencial de salida adaptada a las dos clases de interés (presencia o ausencia de cardiomegalia).

En segundo lugar, se ha modificado la función de propagación hacia adelante (*forward pass*) de la red original. Se ha inyectado una capa de *Dropout* con una probabilidad $p = 0.3$ justo después de la extracción de características y antes de la capa de agrupamiento (*Global Average Pooling*). Esto se hace ya que en el paper [8] se indica que esta alteración permite mejorar el método *Monte Carlo Dropout*.

Finalmente, se ha adoptado una estrategia de *fine-tuning*. Inicialmente, se congelaron los parámetros de toda la red, para posteriormente descongelar y permitir el cálculo de gradientes de forma exclusiva en las capas más profundas: la nueva capa de clasificación, el *denseblock4* y la capa de normalización *norm5*.

3.3 Configuración del Entrenamiento

La optimización de la red neuronal se ha llevado a cabo utilizando el optimizador Adam, procesando las imágenes en lotes (*batches*) de 16 muestras y empleando la pérdida de entropía cruzada (*Cross-Entropy Loss*) como función objetivo. Para afinar el proceso de aprendizaje, se han asignado tasas de aprendizaje (*learning rates*) diferenciadas según el bloque de la red: se ha aplicado 10^{-3} para el clasificador, y 10^{-4} para el *denseblock4* y la capa *norm5*. Además, se ha integrado un planificador de tipo *Cosine Annealing* para reducir progresivamente la tasa de aprendizaje durante

las épocas de entrenamiento, alcanzando un mínimo de $5 \cdot 10^{-4}$.

Para prevenir el desgaste computacional excesivo y almacenar los mejores resultados, se ha implementado un sistema de guardado de puntos de control (*check-points*) basado en la función de pérdida del conjunto de validación. Este proceso de entrenamiento es el que se emplea en el proceso iterativo de la implementación de las técnicas de active learning. Aun así, se ha entrenado un modelo baseline mediante el método tradicional para compararlo con las técnicas de active learning. Este modelo se ha entrenado durante 10 épocas y se ha utilizado el 70% de los datos del conjunto total para el entrenamiento, el 20% para la validación y el 10% para el testeo.

3.4 Implementación del Ciclo de Active Learning

La adaptación final respecto al repositorio original radica en la construcción de un ciclo iterativo y automatizado de *Active Learning*. Este proceso se ha estructurado del modo de que se ejecuta durante múltiples rondas consecutivas, permitiendo registrar la evolución de las métricas de rendimiento en función de la cantidad de muestras activamente anotadas.

3.4.1 Entrenamiento inicial:

Se entrena el modelo base adaptado utilizando únicamente el conjunto de datos etiquetados disponible inicialmente, es decir, el 20%, 30% y 50% de los datos.

3.4.2 Evaluación:

Tras cada ronda, se evalúan métricas clave como el *Accuracy*, el *Recall* y el *F1-score* sobre el conjunto estático de testeo

para monitorizar la mejora progresiva. En total, se realizan 5 rondas por cada método utilizado.

3.4.3 Consulta:

El modelo realiza inferencia sobre la totalidad del conjunto de datos no etiquetado (*unlabeled pool*), a partir del cual se seleccionan las instancias que se incorporarán al conjunto de entrenamiento para reentrenar los modelos. Las técnicas utilizadas son Random, Margin, Entropy, MC Dropout ($p = 0.3$) y MedAL [4].

3.4.4 Adquisición y Reentrenamiento:

Se seleccionan las $n = 100$ imágenes correspondientes a las métricas utilizadas. Estas muestras se eliminan del *pool* no etiquetado y se añadirán al conjunto de entrenamiento, simulando la intervención del oráculo. A continuación, el modelo retoma el aprendizaje desde su último *checkpoint* para integrar los nuevos patrones visuales. Aunque el modelo retome su último *checkpoint*, se utilizan todos los elementos del conjunto de entrenamiento nuevo para entrenar el modelo. En cada ronda se utilizan 10 épocas para el entrenamiento.

4 Resultados

En esta sección se recopilan los resultados obtenidos, dando una interpretación de ellos.

4.1 Modelo baseline

Antes de aplicar las estrategias de *Active Learning*, se evaluó el rendimiento de un modelo *baseline* sobre el conjunto de test para establecer un punto de referencia. Los resultados obtenidos se resumen en la Tabla 1.

Métrica	Valor (%)
Accuracy	92.69
Recall	78.57
F1-score	34.92

Table 1 Resultados de evaluación del modelo baseline.

El modelo logra un *Accuracy* del 92.69% y un *Recall* del 78.57%, pero su bajo *F1-score* (34.92%) evidencia el impacto del severo desbalance de clases original (solo 2.52% de positivos), lo que penaliza fuertemente a los falsos positivos. Estos resultados establecen la línea base para evaluar el impacto de las estrategias de aprendizaje activo.

4.2 20% de los datos son etiquetados




Fig. 4 F1-score en el conjunto de test




Fig. 5 Recall en el conjunto de test




Fig. 6 Accuracy en el conjunto de test

Las estrategias de Aprendizaje Activo muestran una alta sensibilidad al tamaño del conjunto etiquetado, con fluctuaciones marcadas en todas las métricas (ver las figuras 4,5,6). Los métodos basados en incertidumbre, específicamente *Entropy* y *Margin*, superan consistentemente al muestreo *Random*, alcanzando picos de F1-score ($\sim 42\%$) y *accuracy* ($\sim 96.5\%$) con 1100 muestras. Por su parte, *MC Dropout 0.3* logra el mayor *recall* ($\sim 85\%$) a las 1200 muestras, aunque presenta una degradación posterior. En contraste, el método *MedAL* exhibe el desempeño más inestable, con caídas drásticas tras superar las 1100 muestras, lo que sugiere que, para este *dataset*, los enfoques de incertidumbre simple resultan más eficaces que los esquemas representativos o bayesianos.

4.3 30% de los datos son etiquetados

Al evaluar el modelo partiendo de un conjunto inicial del 30% de datos etiquetados, se observa una dinámica diferente a la del escenario del 20%, caracterizada por una acusada inestabilidad general en todas las métricas.

Al analizar la evolución de las métricas (ver Figuras 7, 8 y 9), se evidencia que la incorporación de nuevas muestras no garantiza una mejora lineal




Fig. 7 F1-score en el conjunto de test con 30% de datos iniciales




Fig. 8 Recall en el conjunto de test con 30% de datos iniciales




Fig. 9 Accuracy en el conjunto de test con 30% de datos iniciales

del rendimiento. En términos de *F1-score* y *Accuracy*, la estrategia *MedAL* destaca en las primeras iteraciones antes de decaer progresivamente, mientras que los métodos de incertidumbre simple (*Entropy* y *Margin*) logran sus mejores registros (cercaos al 42% y al 95.5%, respectivamente) en torno a las 1650 muestras. Respecto al *Recall*, se aprecian fluctuaciones extremas: *Entropy* y *Random* alcanzan picos del 85% en etapas intermedias, y *MedAL* muestra una

fuerte recuperación al final del ciclo, contrastando con *MC Dropout 0.3*, que sufre el peor desempeño global con caídas severas hasta el 50%. En conclusión, tanto las estrategias basadas en incertidumbre como los enfoques más complejos alcanzan picos de rendimiento notables en momentos puntuales, pero adolecen de una marcada inestabilidad a lo largo de todo el proceso de selección activa en este escenario.

4.4 60% de los datos son etiquetados

Al evaluar el escenario con un 60% de datos etiquetados (ver Figuras 10, 11 y ??), se observa una evolución mucho más consistente y una clara superioridad del *Active Learning* frente al muestreo aleatorio.




Fig. 10 Accuracy en el conjunto de test con 60% de datos iniciales




Fig. 11 Recall en el conjunto de test con 60% de datos iniciales




Fig. 12 F1 en el conjunto de test con 60% de datos iniciales

En términos de *F1-score* y *Recall*, estrategias avanzadas como *MedAL* y *MC Dropout* muestran una fuerte tendencia ascendente, superando el 40% y el 55% respectivamente en las rondas finales. Destaca especialmente el dominio de *MedAL* en la detección de casos positivos (*Recall* superior al 60%), contrastando drásticamente con la fuerte caída del método *Random* (hasta el 30%). En cuanto al *Accuracy*, aunque existen ciertas fluctuaciones, métodos como *Margin* y *MedAL* logran consolidar valores cercanos al 95%. En resumen, al partir de una base de conocimiento más amplia, los enfoques más complejos (como *MedAL* y la estimación bayesiana de *MC Dropout*) logran aprovechar eficientemente la adición de nuevas muestras, demostrando ser mucho más robustos que el muestreo tradicional.

Method	labeled=20%	labeled=30%	labeled=60%	Baseline
Random	(93, 64, 31.8)	(89.5, 85.7, 28.9)	(92.2, 60.3, 38.6)	(92.69, 78.57, 34.92)
Margin	(92, 64, 31.8)	(92.3, 71.4, 31.7)	(92.69, 8.37, 9)	(92.69, 78.57, 34.92)
Entropy	(94.5, 64, 36.5)	(92.5, 64.3, 30)	(93.4, 67.3, 39.1)	(92.69, 78.57, 34.92)
MC Dropout	(95, 50, 33.5)	(94.1, 50, 29.8)	(93.1, 72.2, 41)	(92.69, 78.57, 34.92)
MedAL	(92, 57, 26.2)	(90, 85.7, 30)	(94.5, 71.3, 40.8)	(92.69, 78.57, 34.92)

Table 2 Comparación de los métodos utilizados teniendo en cuenta los resultados (Accuracy, Recall, F1-score) de la última ronda.

Los resultados muestran que la *accuracy* se mantiene relativamente estable entre los distintos métodos y porcentajes de datos etiquetados. Esto

indica que esta métrica no resulta especialmente discriminativa para evaluar el impacto de las estrategias de *active learning*. En cambio, las diferencias más relevantes aparecen en las métricas de *recall* y especialmente en el F1-score. Con únicamente un 20% de los datos etiquetados, el método basado en entropía obtiene el mejor F1-score (36.5), superando incluso al modelo entrenado con selección aleatoria y aproximándose al rendimiento del modelo *baseline*. En este escenario con pocos datos, las estrategias basadas en incertidumbre parecen ser las más efectivas para seleccionar ejemplos informativos.

Al aumentar la proporción de datos etiquetados, el rendimiento general mejora progresivamente. Con un 60% de los datos, varios métodos de *active learning* superan claramente al *baseline*, alcanzando valores de F1-score superiores a 40, frente al 34.92 obtenido por el modelo entrenado de forma convencional con el 100% de los datos etiquetados. Esto sugiere que las estrategias de selección activa permiten aprovechar de forma más eficiente el proceso de anotación, logrando resultados comparables o incluso superiores al entrenamiento tradicional utilizando una fracción significativamente menor de datos etiquetados.

5 Discusión y líneas futuras

Los resultados validan el potencial del *Active Learning* para optimizar el diagnóstico radiológico, superando al modelo *baseline* empleando solo una fracción de los datos. No obstante, el sistema muestra una alta sensibilidad al tamaño del conjunto de entrenamiento.

Las marcadas fluctuaciones observadas en *Recall* y *F1-score* son consecuencia directa del severo desbalance de clases original, donde mínimas variaciones en la adición de muestras positivas alteran drásticamente la capacidad del clasificador.

Por otro lado, este marco iterativo presenta un elevado coste computacional debido a los continuos reentrenamientos. Como línea de trabajo futuro para optimizar el esfuerzo del especialista, se propone diseñar un sistema de asistencia interactiva para el oráculo. Al evaluar una instancia incierta, la herramienta mostraría ejemplos visualmente similares extraídos del conjunto ya etiquetado, ofreciendo una referencia directa que agilizaría la anotación y minimizaría posibles sesgos.

Finalmente, a nivel algorítmico se plantea investigar la calibración de la incertidumbre epistémica en *MC Dropout*. Evaluar distintos valores de probabilidad de desconexión p (frente al $p = 0.3$ estático actual) permitiría ajustar la varianza de las predicciones estocásticas, logrando una estimación de incertidumbre más robusta y, por consiguiente, una selección de muestras aún más precisa.

References

- [1] Rajpurkar, P., Irvin, J., Zhu, K., Yang, B., Mehta, H., Duan, T., Ding, D., Bagul, A., Langlotz, C.P., Shpanskaya, K., Lungren, M.P., Ng, A.Y.: Chexnet: Radiologist-level pneumonia detection on chest x-rays with deep learning (2017) [arXiv:1711.05225](https://arxiv.org/abs/1711.05225)

- [2] Nasir, M.: CheXNet: Radiologist-Level Pneumonia Detection on Chest X-Rays with Deep Learning. GitHub repository. <https://github.com/nasir6/chexnet>
- [3] Gal, Y., Ghahramani, Z.: Dropout as a bayesian approximation: Representing model uncertainty in deep learning. In: Balcan, M.F., Weinberger, K.Q. (eds.) Proceedings of The 33rd International Conference on Machine Learning. Proceedings of Machine Learning Research, vol. 48, pp. 1050–1059. PMLR, New York, New York, USA (2016). <https://proceedings.mlr.press/v48/gal16.html>
- [4] Smailagic, A., Noh, H.Y., Campilho, A., Costa, P., Walawalkar, D., Khandelwal, K., Mirshekari, M., Fagert, J., Galdran, A., Xu, S.: Medal: Accurate and robust deep active learning for medical image analysis. In: Proceedings of the 17th IEEE International Conference on Machine Learning and Applications (ICMLA). IEEE, Orlando, FL, USA (2018). <https://arxiv.org/abs/1809.09287>
- [5] Huang, G., Liu, Z., Van Der Maaten, L., Weinberger, K.Q.: Densely connected convolutional networks (2017) [arXiv:1608.06993](https://arxiv.org/abs/1608.06993)
- [6] Zhou, B., Khosla, A., Lapedriza, A., Oliva, A., Torralba, A.: Learning deep features for discriminative localization, 2921–2929 (2016) [arXiv:1512.04150](https://arxiv.org/abs/1512.04150)
- [7] Yu, H., Yang, L., Zhang, R., Luo, H., Yang, J.: A survey on active learning and human-in-the-loop deep learning for medical image analysis. Medical Image Analysis **71**, 102062 (2021) <https://doi.org/10.1016/j.media.2021.102062>
- [8] Seeböck, A., Orlando, J.I., Schlegl, T., Waldstein, S.M., Bogunović, H., Klimesch, S., Gerendas, B.S., Schmidt-Erfurth, U., Langs, G.: Active learning in brain tumor segmentation with uncertainty sampling and annotation redundancy restriction, 206–214 (2019) [arXiv:2302.10185](https://arxiv.org/abs/2302.10185)